

Hotel Booking Cancellation Analysis

by Izzan Muhammad Fa'iz

ABOUT ME

Izzan Muhammad Fa'iz

Memiliki kemampuan dalam pengolahan, analisis, dan visualisasi data menggunakan Python serta berbagai tools pendukung analitik. Berpengalaman dalam mengelola data, membangun dashboard monitoring real-time, dan menghasilkan insight yang mendukung pengambilan keputusan. Siap berkontribusi sebagai Data Analyst, maupun posisi terkait pengelolaan dan analisis data dalam lingkungan kerja yang dinamis dan berbasis teknologi.



Contact me!

 izzanmfaiz@gmail.com

 [Izzan Muhammad Fa'iz](#)

 [Click here for my GitHub!](#)

Education: Academic & Professional Training

1

SI Teknik Komputer – Universitas Telkom (2021–2025)

- Fokus pada Pengembangan Perangkat Lunak, Sistem IoT, Sistem Basis Data, Sistem Embedded, Pengembangan Mobile, dan Analitik Data.
- Mata kuliah relevan: Pemrograman dengan Python, Manajemen Basis Data, Rekayasa Perangkat Lunak, Struktur Data & Algoritma.
- Skripsi: "Perancangan dan Implementasi Sistem Monitoring Kualitas Air Real-Time Berbasis IoT Menggunakan Flutter dan Firebase untuk Budidaya Udang."



2

Data Analyst Bootcamp Dibimbing.id (2026–Present)

- Menguasai pengalaman praktis dalam analitik data menggunakan SQL, Python, Excel, Power BI, Tableau, dan Looker Studio.
- Mempelajari data cleaning, exploratory data analysis (EDA), visualisasi data, pengembangan dashboard, segmentasi pelanggan, analitik pemasaran, dan business intelligence untuk mengubah data menjadi wawasan yang dapat ditindaklanjuti.



Previous Projects




“Profitability & Discount Impact Analysis”

Analisis ini menunjukkan bahwa tingginya penjualan belum diikuti profit yang optimal. Kategori Technology memberikan kontribusi profit terbesar, sedangkan Furniture, khususnya Tables, mengalami kerugian signifikan. Diskon tinggi (>40%) terbukti menurunkan profit, sementara transaksi dengan diskon rendah atau tanpa diskon menghasilkan keuntungan lebih baik.



“Data Analysis with SQL”

Sekitar 10,7% pesanan mengalami kendala pengiriman dengan rata-rata waktu 12 hari. Metode Credit Card mendominasi pembayaran sebesar 78,6% dari total nilai transaksi, sementara segmen High Payment menyumbang lebih dari separuh nilai pembayaran. Diperlukan peningkatan pengawasan logistik, investigasi keterlambatan ekstrem, serta optimalisasi promosi dan retensi pelanggan bernilai tinggi untuk menjaga performa bisnis.



“People Analytics”

Sekitar 25% kandidat berpotensi berpindah kerja. Risiko tertinggi ada pada Entry Level dan kandidat tanpa pengalaman relevan. Faktor utama yang memengaruhi adalah pengalaman kerja, pendidikan, dan tipe perusahaan. Strategi retensi perlu difokuskan pada segmen berisiko dengan onboarding, pelatihan, dan pendekatan retensi yang sesuai.

Problem Statement

Industri perhotelan menghadapi tantangan dalam mengelola booking cancellation karena pembatalan dapat mengganggu perencanaan okupansi, forecasting, dan revenue management. Studi hospitality menunjukkan bahwa **cancellation behavior berkaitan dengan karakteristik reservasi seperti booking lead time, booking channel, dan kebijakan pembatalan.** [1].

Oleh karena itu, analisis dilakukan untuk mengidentifikasi pola reservasi dan segmen dengan risiko pembatalan tinggi berdasarkan lead time, deposit type, market segment, serta karakteristik pelanggan.

“Faktor dan pola reservasi apa yang paling berkaitan dengan tingginya risiko pembatalan hotel?”



Data Understanding

Column	Description
hotel	Nama hotel tempat reservasi dilakukan
is_canceled	Status apakah reservasi dibatalkan atau tidak (0 = tidak dibatalkan, 1 = dibatalkan)
lead_time	Jumlah hari antara tanggal pemesanan dan tanggal kedatangan
arrival_date_year	Tahun kedatangan customer
arrival_date_month	Bulan kedatangan customer
arrival_date_week_number	Nomor minggu dalam tahun saat customer dijadwalkan datang
arrival_date_day_of_month	Tanggal kedatangan customer dalam bulan
stays_in_weekend_nights	Jumlah malam menginap pada hari weekend
stays_in_week_nights	Jumlah malam menginap pada hari weekday
adults	Jumlah tamu dewasa dalam reservasi
children	Jumlah anak dalam reservasi
babies	Jumlah bayi dalam reservasi
meal	Jenis paket makanan yang dipilih customer
country	Negara asal customer berdasarkan kode negara
market_segment	Segmen pasar dari reservasi

Data Overview

Dataset berisi data reservasi hotel yang digunakan untuk menganalisis pola booking dan pembatalan reservasi. Dataset mencakup informasi mengenai karakteristik reservasi, waktu pemesanan, tipe hotel, segmentasi pasar, deposit, serta perilaku pelanggan.
Datase

Baris : 83,293

Kolom : 33

Format Data : CSV

[Click here for the link!](#)

Data Understanding

Column	Description
distribution_channel	Channel distribusi yang digunakan untuk mendapatkan reservasi
is_repeated_guest	Menunjukkan apakah customer merupakan repeated guest (0 = bukan, 1 = ya)
previous_cancellations	Jumlah reservasi customer sebelumnya yang pernah dibatalkan
previous_bookings_not_canceled	Jumlah reservasi customer sebelumnya yang tidak dibatalkan
reserved_room_type	Tipe kamar yang dipesan oleh customer
assigned_room_type	Tipe kamar yang diberikan kepada customer
booking_changes	Jumlah perubahan yang dilakukan terhadap reservasi
deposit_type	Jenis kebijakan deposit yang diterapkan pada reservasi
agent	ID travel agent yang menangani reservasi
company	ID perusahaan yang terkait dengan reservasi
days_in_waiting_list	Jumlah hari reservasi berada dalam waiting list
customer_type	Jenis customer atau tipe reservasi
adr	Average Daily Rate, yaitu rata-rata tarif kamar per malam
required_car_parking_spaces	Jumlah tempat parkir yang dibutuhkan customer
total_of_special_requests	Jumlah special request yang dibuat oleh customer
reservation_status	Status akhir reservasi
reservation_status_date	Tanggal terakhir status reservasi tercatat
bookingID	ID unik untuk setiap reservasi

Data Overview

Dataset berisi data reservasi hotel yang digunakan untuk menganalisis pola booking dan pembatalan reservasi. Dataset mencakup informasi mengenai karakteristik reservasi, waktu pemesanan, tipe hotel, segmentasi pasar, deposit, serta perilaku pelanggan.

Datase

Baris : 83,293

Kolom : 33

Format Data : CSV

[Click here for the link!](#)

Data Understanding

```
<class 'pandas.DataFrame'>
RangeIndex: 83293 entries, 0 to 83292
Data columns (total 33 columns):
 #   Column                                Non-Null Count  Dtype
---  -
 0   hotel                                83293 non-null  str
 1   is_canceled                          83293 non-null  int64
 2   lead_time                            83293 non-null  int64
 3   arrival_date_year                    83293 non-null  int64
 4   arrival_date_month                   83293 non-null  str
 5   arrival_date_week_number             83293 non-null  int64
 6   arrival_date_day_of_month             83293 non-null  int64
 7   stays_in_weekend_nights              83293 non-null  int64
 8   stays_in_week_nights                 83293 non-null  int64
 9   adults                               83293 non-null  int64
10  children                             83290 non-null  float64
11  babies                              83293 non-null  int64
12  meal                                 83293 non-null  str
13  country                             82947 non-null  str
14  market_segment                       83293 non-null  str
15  distribution_channel                  83293 non-null  str
16  is_repeated_guest                     83293 non-null  int64
17  previous_cancellations                 83293 non-null  int64
18  previous_bookings_not_canceled         83293 non-null  int64
19  reserved_room_type                    83293 non-null  str
...
31  reservation_status_date                83293 non-null  str
32  bookingID                             83293 non-null  int64
dtypes: float64(4), int64(17), str(12)
```

Data Structure & Type

Dataset terdiri dari 83.293 data reservasi hotel dengan 33 variabel yang mencakup informasi hotel, reservasi, pelanggan, market segment, deposit, harga, dan status reservasi.

Data Preprocessing

Missing Value and Duplicate

Missing Value

Pengecekan missing value dilakukan untuk memastikan kelengkapan data sebelum analisis. Ditemukan missing value pada 4 variabel, dengan tingkat missing yang berbeda.

company memiliki missing value tertinggi **sebesar 94,32%**, diikuti **agent sebesar 13,69%**, **country sebesar 0,42%**, dan children sebesar **0,004%**.

Missing value pada company dan agent **tidak langsung dihapus** karena kedua variabel memiliki proporsi missing yang cukup besar dan penghapusan dapat menyebabkan kehilangan banyak observasi. **Penanganan dilakukan dengan mempertimbangkan relevansi variabel** terhadap analisis.

Duplicate Data

Pengecekan duplikasi dilakukan untuk memastikan setiap reservasi tidak dihitung lebih dari satu kali. Hasil pemeriksaan **menunjukkan 0 duplicate records**, sehingga tidak diperlukan penghapusan data akibat duplikasi.

	Missing Count	Missing Percentage
company	78559	94.316449
agent	11404	13.691427
country	346	0.415401
children	3	0.003602

```
Duplicate rows: 0
```

Feature Engineering

Lead Time Category

lead_time dikelompokkan menjadi beberapa kategori untuk mengidentifikasi tingkat risiko cancellation berdasarkan jarak antara waktu pemesanan dan tanggal kedatangan.

Tujuan: memudahkan identifikasi booking dengan lead time panjang yang memiliki cancellation rate lebih tinggi.

Total Guests

Jumlah tamu dihitung dari:
adults + children + babies

Tujuan: memahami karakteristik ukuran kelompok yang melakukan reservasi.

Total Stay Nights

Lama menginap dihitung dari:
stays_in_weekend_nights + stays_in_week_nights

Tujuan: menganalisis hubungan durasi menginap dengan karakteristik booking dan cancellation.

	total_bookings	cancellations	cancellation_rate
lead_time_category			
0–7 days	13739	1338	9.738700
8–30 days	13205	3638	27.550170
31–60 days	11970	4316	36.056809
61–90 days	8731	3469	39.731989
91–120 days	7282	3241	44.507004
121–180 days	11216	5031	44.855563
181–270 days	9289	4517	48.627409
271–373 days	5749	3823	66.498521
>373 days	2112	1404	66.477273
Unknown	0	0	NaN

Feature Engineering

Total Previous Bookings

Riwayat booking sebelumnya digabungkan dari:
previous_bookings_not_canceled + previous_cancellations

Tujuan: menggambarkan pengalaman booking pelanggan sebelumnya.

Special Requests Category

total_of_special_requests dikategorikan berdasarkan jumlah permintaan khusus pelanggan.

Tujuan: mempermudah analisis hubungan antara customer engagement dan cancellation rate.

Dataset yang berawal dari 33 variabel menjadi 42 variabel.

	total_bookings	cancellations	cancellation_rate
arrival_date_month			
January	4214	1298	30.802088
February	5560	1912	34.388489
March	6810	2197	32.261380
April	7787	3179	40.824451
May	8222	3264	39.698370
June	7666	3147	41.051396
July	8731	3243	37.143512
August	9643	3619	37.529814
September	7398	2833	38.294134
October	7741	2935	37.914998
November	4779	1505	31.491944
December	4742	1645	34.690004

Outliers

Pengecekan outlier dilakukan menggunakan metode Interquartile Range (IQR) pada variabel numerik untuk mengidentifikasi nilai yang berada jauh dari distribusi utama data.

Beberapa variabel menunjukkan nilai ekstrem, terutama lead time, ADR, total stay nights, dan days in waiting list. Namun, nilai tersebut tidak langsung dihapus karena dapat merepresentasikan kondisi reservasi yang benar-benar terjadi.

	Column	Q1	Q3	Lower Bound	Upper Bound	Outlier Count	Outlier %
3	adults	2.00	2.0	2.000	2.000	20920	25.116156
8	booking_changes	0.00	0.0	0.000	0.000	12703	15.250981
4	children	0.00	0.0	0.000	0.000	5961	7.156664
11	required_car_parking_spaces	0.00	0.0	0.000	0.000	5109	6.133769
6	previous_cancellations	0.00	0.0	0.000	0.000	4397	5.278955
10	adr	69.53	126.0	-15.175	210.705	2672	3.207953
9	days_in_waiting_list	0.00	0.0	0.000	0.000	2594	3.114307
7	previous_bookings_not_canceled	0.00	0.0	0.000	0.000	2532	3.039871
2	stays_in_week_nights	1.00	3.0	-2.000	6.000	2355	2.827368
0	lead_time	18.00	160.0	-195.000	373.000	2112	2.535627
12	total_of_special_requests	0.00	1.0	-1.500	2.500	2017	2.421572
5	babies	0.00	0.0	0.000	0.000	643	0.771974
1	stays_in_weekend_nights	0.00	2.0	-3.000	5.000	196	0.235314


Exploratory Data Analysis

Cancellation Distribution

Dari total 83.293 booking, **sebanyak 30.777 booking (36,95%) mengalami pembatalan**, sedangkan **52.516 booking (63,05%) tidak dibatalkan**.

Tingkat cancellation yang mencapai lebih dari sepertiga total reservasi menunjukkan bahwa pembatalan merupakan isu yang **cukup signifikan** bagi operasional hotel, karena dapat memengaruhi tingkat okupansi, perencanaan kamar, dan potensi pendapatan.

Oleh karena itu, analisis selanjutnya **difokuskan untuk mengidentifikasi faktor dan karakteristik booking** yang memiliki risiko cancellation lebih tinggi.




Exploratory Data Analysis

Cancellation Rate by Lead Time

Analisis menunjukkan bahwa cancellation rate meningkat seiring semakin panjangnya lead time. Booking dengan **lead time 0–7 hari** memiliki cancellation rate terendah **sebesar 9,74%**, sedangkan booking dengan **lead time 271–373 hari mencapai 66,50%** dan **>373 hari sebesar 66,48%**.


Hal ini menunjukkan bahwa booking yang dibuat jauh sebelum tanggal kedatangan memiliki risiko pembatalan yang lebih tinggi. Namun, lead time tidak dapat dianggap sebagai satu-satunya faktor penyebab cancellation, sehingga perlu dianalisis bersama karakteristik booking lainnya.





Exploratory Data Analysis

Heatmap Correlation

Analisis korelasi dilakukan untuk mengidentifikasi hubungan antara faktor-faktor booking dengan keputusan cancellation. Hasil menunjukkan bahwa lead time memiliki korelasi positif **paling tinggi dengan cancellation ($r = 0,29$)**, yang menunjukkan bahwa semakin jauh jarak antara waktu pemesanan dan tanggal kedatangan, semakin tinggi kecenderungan booking untuk dibatalkan.







Seberapa besar cancellation menjadi masalah bagi performa reservasi hotel?

Cancellation mencapai 36,95% dari seluruh reservasi, atau sekitar 1 dari setiap 3 booking. Proporsi ini menunjukkan bahwa cancellation bukan sekadar kejadian minor, tetapi merupakan bagian signifikan dari aktivitas reservasi yang perlu diperhatikan dalam pengelolaan okupansi dan inventory hotel.

Tingginya jumlah pembatalan dapat menyebabkan ketidakpastian okupansi dan potensi kehilangan revenue, terutama ketika kamar yang sebelumnya dipesan tidak berhasil dijual kembali.

83293


Total Bookings

30777

Cancelled Bookings

36.95%



Cancellation Rate



Apakah semakin panjang lead time meningkatkan risiko cancellation?

Terlihat pola yang cukup konsisten, semakin jauh booking dilakukan dari tanggal kedatangan, **semakin tinggi** cancellation rate. Cancellation rate meningkat seiring bertambahnya lead time, dari **9,74% pada booking 0–7 hari hingga 66,50% pada booking 271–373** hari. Korelasi lead time terhadap cancellation sebesar 0,29.


Booking dengan lead time panjang memiliki risiko cancellation yang lebih tinggi, sehingga hotel perlu melakukan monitoring lebih awal terhadap reservasi tersebut untuk mengurangi potensi kamar kosong.



Apakah deposit type berkaitan dengan cancellation?

Dari data yang ditunjukkan, Booking dengan Non Refund memiliki **cancellation rate 99,32%**, jauh lebih tinggi dibandingkan **No Deposit (28,25%)** dan **Refundable (21,82%)**.

Artinya, Perbedaan yang sangat besar menunjukkan bahwa deposit type merupakan karakteristik penting dalam segmentasi risiko cancellation. Booking dengan pola tersebut perlu dianalisis dan dimonitor lebih lanjut sebelum digunakan sebagai dasar kebijakan.



Booking seperti apa yang memiliki risiko cancellation paling tinggi?

Kombinasi lead time panjang dan Non Refund menunjukkan cancellation rate yang sangat tinggi. Beberapa segmen bahkan **mencapai 100% cancellation**, seperti **booking 271–373 hari + Non Refund** dan **>373 hari + Non Refund**.

Kombinasi karakteristik tersebut dapat digunakan untuk mengidentifikasi high-risk booking, sehingga hotel dapat melakukan tindakan mitigasi lebih awal terhadap reservasi yang berpotensi batal.

lead_time_category	deposit_type	Total Bookings	Cancelled Bookings	Cancellation Rate
271–373 days	Non Refund	2377	2377	100.00%
>373 days	Non Refund	1232	1232	100.00%
91–120 days	Non Refund	1064	1063	99.91%
31–60 days	Non Refund	683	682	99.85%
61–90 days	Non Refund	1001	997	99.60%
181–270 days	Non Refund	1612	1605	99.57%
121–180 days	Non Refund	1822	1791	98.30%
8–30 days	Non Refund	332	320	96.39%
271–373 days	No Deposit	3357	1442	42.96%
181–270 days	No Deposit	7673	2911	37.94%
91–120 days	No Deposit	6218	2178	35.03%
121–180 days	No Deposit	9334	3227	34.57%
31–60 days	No Deposit	11283	3633	32.20%
61–90 days	No Deposit	7728	2470	31.96%
8–30 days	No Deposit	12855	3316	25.80%
>373 days	No Deposit	878	171	19.48%
0–7 days	No Deposit	13653	1270	9.30%

Conclusion

Berdasarkan hasil insight, berikut beberapa kesimpulan utama:

- Cancellation merupakan masalah yang cukup signifikan karena **mencapai 36,95% dari 83.293 booking, atau sekitar 1 dari setiap 3 reservasi**. Tingginya cancellation dapat meningkatkan **ketidakpastian okupansi** dan **menyebabkan potensi kehilangan revenue**, terutama apabila kamar yang **dibatalkan tidak berhasil dijual kembali**.
- Data menunjukkan pola yang jelas bahwa semakin panjang **lead time**, semakin **tinggi cancellation rate**. Cancellation **meningkat dari 9,74% pada booking 0–7 hari hingga 66,50% pada booking 271–373 hari, dengan korelasi sebesar 0,29** yang menunjukkan hubungan positif namun relatif lemah.
- Deposit type menunjukkan perbedaan **cancellation yang sangat besar**. Booking Non Refund memiliki **cancellation rate 99,32%**, sedangkan **No Deposit 28,25%** dan **Refundable 21,82%**.
- Booking dengan **kombinasi lead time panjang dan Non Refund** merupakan segmen dengan risiko cancellation tertinggi. Beberapa kombinasi bahkan **mencapai 100% cancellation, seperti 271–373 hari + Non Refund dan >373 hari + Non Refund**.

Recommendation

Early Warning System

Identifikasi booking dengan lead time panjang dan karakteristik risiko tinggi untuk dilakukan monitoring dan confirmation lebih awal.

Segment-Based Cancellation Policy

Sesuaikan kebijakan cancellation dan deposit berdasarkan tingkat risiko booking, bukan menerapkan satu kebijakan untuk seluruh customer.

High-Risk Booking Segmentation

Mencari beberapa segment dari faktor-faktor lain untuk menentukan prioritas penanganan booking yang lebih akurat.

Data-Driven Revenue Management

Gunakan historical cancellation untuk forecasting occupancy dan controlled overbooking, sehingga kamar yang berpotensi kosong dapat diminimalkan tanpa meningkatkan risiko overbooking secara berlebihan.

Limitasi Analisa

Beberapa kategori memiliki distribusi yang tidak seimbang

Beberapa kategori booking memiliki jumlah observasi yang jauh berbeda. Hal ini dapat membuat cancellation rate pada kategori tertentu terlihat sangat ekstrem.

Potensi faktor eksternal belum tercakup

Faktor pada data belum mencakup dengan faktor-faktor eksternal sehingga perubahan cancellation rate tidak dapat dijelaskan hanya berdasarkan variabel yang tersedia dalam dataset.

Korelasi $\neq$ Kausalitas

Hubungan antarvariabel menunjukkan pola, tetapi tidak membuktikan hubungan sebab-akibat.

Thank you!

CONTACT



+62 857 2014 1459



izzanmfaiz@gmail.com



Izzan Muhammad Fa'iz



<https://github.com/ImaWeaverBear>