

RETAIL SALES PERFORMANCE & REVENUE ANALYSIS

by Izzan Muhammad Fa'iz

ABOUT ME

Izzan Muhammad Fa'iz

Memiliki kemampuan dalam pengolahan, analisis, dan visualisasi data menggunakan Python serta berbagai tools pendukung analitik. Berpengalaman dalam mengelola data, membangun dashboard monitoring real-time, dan menghasilkan insight yang mendukung pengambilan keputusan. Siap berkontribusi sebagai Data Analyst, maupun posisi terkait pengelolaan dan analisis data dalam lingkungan kerja yang dinamis dan berbasis teknologi.



Contact me!

✉ izzanmfaiz@gmail.com

 [Izzan Muhammad Fa'iz](#)

 [Click here for my GitHub!](#)

Education: Academic & Professional Training

1

S1 Teknik Komputer – Universitas Telkom (2021–2025)

- Fokus pada Pengembangan Perangkat Lunak, Sistem IoT, Sistem Basis Data, Sistem Embedded, Pengembangan Mobile, dan Analitik Data.
- Mata kuliah relevan: Pemrograman dengan Python, Manajemen Basis Data, Rekayasa Perangkat Lunak, Struktur Data & Algoritma.
- Skripsi: "Perancangan dan Implementasi Sistem Monitoring Kualitas Air Real-Time Berbasis IoT Menggunakan Flutter dan Firebase untuk Budidaya Udang."



2

Data Analyst Bootcamp Dibimbing.id (2026–Present)

- Menguasai pengalaman praktis dalam analitik data menggunakan SQL, Python, Excel, Power BI, Tableau, dan Looker Studio.
- Mempelajari data cleaning, exploratory data analysis (EDA), visualisasi data, pengembangan dashboard, segmentasi pelanggan, analitik pemasaran, dan business intelligence untuk mengubah data menjadi wawasan yang dapat ditindaklanjuti.



Previous Projects




“Profitability & Discount Impact Analysis”

Analisis ini menunjukkan bahwa tingginya penjualan belum diikuti profit yang optimal. Kategori Technology memberikan kontribusi profit terbesar, sedangkan Furniture, khususnya Tables, mengalami kerugian signifikan. Diskon tinggi (>40%) terbukti menurunkan profit, sementara transaksi dengan diskon rendah atau tanpa diskon menghasilkan keuntungan lebih baik.



“Data Analysis with SQL”

Sekitar 10,7% pesanan mengalami kendala pengiriman dengan rata-rata waktu 12 hari. Metode Credit Card mendominasi pembayaran sebesar 78,6% dari total nilai transaksi, sementara segmen High Payment menyumbang lebih dari separuh nilai pembayaran. Diperlukan peningkatan pengawasan logistik, investigasi keterlambatan ekstrem, serta optimalisasi promosi dan retensi pelanggan bernilai tinggi untuk menjaga performa bisnis.



“People Analytics”

Sekitar 25% kandidat berpotensi berpindah kerja. Risiko tertinggi ada pada Entry Level dan kandidat tanpa pengalaman relevan. Faktor utama yang memengaruhi adalah pengalaman kerja, pendidikan, dan tipe perusahaan. Strategi retensi perlu difokuskan pada segmen berisiko dengan onboarding, pelatihan, dan pendekatan retensi yang sesuai.

Problem Statement

Industri retail menghasilkan data transaksi yang dapat dimanfaatkan untuk memahami tren penjualan, pelanggan, dan produk. Retail analytics membantu mengubah data tersebut menjadi insight untuk mendukung keputusan terkait penjualan dan profitabilitas. [1]

Namun, performa bisnis tidak cukup dinilai dari total penjualan saja. Analisis perlu mempertimbangkan produk, pelanggan, lokasi toko, dan waktu transaksi untuk mengetahui faktor yang berkaitan dengan performa revenue.

“Bagaimana pola penjualan dan faktor produk, pelanggan, toko, serta waktu berkaitan dengan performa revenue retail?”



Data Understanding

Tools: 

ID	Data da Venda	Quantidade	Preço Unitário	Cliente_ID	customer_name	Gênero	Idade	Cidade	Produto_ID	product_name	Categoria	Cor	Tamanho	Preço
1	2020-04-19 13:51:40	30	175.88	41	Lourenço Branco	M	24	Cascais	259	Harum	Roupas	Vermelho	S	53
2	2016-05-16 04:52:08	90	83.19	308	Frederico Loureiro	M	62	Vila do Corvo	898	Eius	Calçado	Rosa	37	54
3	2018-11-30 17:45:41	88	682.42	910	Ema Leal-Mota	F	31	Silves	357	Quasi	Roupas	Laranja	XS	75
4	2024-12-31 15:53:01	63	365.50	914	Gaspar Neto	M	44	Lisboa	490	Voluptatibus	Roupas	Branco	XL	30
5	2019-03-21 17:00:00	47	182.52	92	Débora Silva	M	65	Faro	341	Suscipit	Roupas	Vermelho	XXL	84

Data Details:

- Venda.csv → Data Sales
- Produtos.csv → Data Product
- Clientes.csv → Data Client
- Lojas.csv → Data Stores

Data Overview

Dataset ini merupakan retail sales dataset yang menggabungkan data transaksi penjualan dengan informasi pelanggan, produk, dan toko untuk menganalisis performa bisnis dari berbagai perspektif.

[Click here for the link!](#)

Data Understanding

```
<class 'pandas.DataFrame'>
RangeIndex: 20000 entries, 0 to 19999
Data columns (total 21 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Venda_ID              20000 non-null  int64
1   Data da Venda         20000 non-null  str
2   Quantidade            20000 non-null  int64
3   Preço Unitário        20000 non-null  float64
4   Cliente_ID            20000 non-null  int64
5   customer_name         20000 non-null  str
6   Género                20000 non-null  str
7   Idade                 20000 non-null  int64
8   Cidade                20000 non-null  str
9   Produto_ID            20000 non-null  int64
10  product_name          20000 non-null  str
11  Categoria              20000 non-null  str
12  Cor                   20000 non-null  str
13  Tamanho               20000 non-null  str
14  Preço                 20000 non-null  float64
15  Custo_Aquisição      20000 non-null  float64
16  Loja_ID               20000 non-null  int64
17  store_name            20000 non-null  str
18  Região                20000 non-null  str
19  store_city            20000 non-null  str
20  Tipo                  20000 non-null  str
dtypes: float64(3), int64(6), str(12)
memory usage: 5.3 MB
```

Data Structure & Type

Dataset memiliki struktur tabular, di mana setiap baris merepresentasikan satu transaksi penjualan, sedangkan setiap kolom merepresentasikan atribut transaksi, customer, product, atau store.

Type Data :

Identifier

sale_id, customer_id, product_id, store_id

Mengidentifikasi transaksi dan entitas

Numerical

quantity, unit_price, age, acquisition_cost

Analisis kuantitatif dan perhitungan metrik

Categorical

gender, category, region, store_type, color, size

Segmentasi dan perbandingan kelompok

Datetime

datetime

Analisis tren dan pola berdasarkan waktu

Text/Label

customer_name, product_name, store_name, city

PRODUCT ANALYSIS LIMITATION!

Analisis pada level individual product tidak dilakukan karena beberapa informasi produk tidak lengkap dan nama produk bersifat ambigu/synthetic, sehingga interpretasi performa produk berisiko menghasilkan insight yang kurang representatif.

Data Preprocessing

Missing Value and Duplicate

Missing Value

Pengecekan dilakukan untuk memastikan tidak terdapat data kosong yang dapat memengaruhi hasil analisis. Dari 20,000 records, tidak ditemukan missing value pada seluruh kolom.

Duplicate Data

Pengecekan duplikasi dilakukan untuk mencegah transaksi yang sama dihitung lebih dari satu kali. Hasil pemeriksaan menunjukkan tidak terdapat duplicate records pada dataset.

Pada dataset ini, hasil pengecekan menunjukkan:

Dataset memiliki tingkat kelengkapan dan konsistensi yang baik, dengan 0 missing values dan 0 duplicate records. Oleh karena itu, tidak diperlukan imputasi maupun penghapusan data akibat duplikasi.

missing_values	
Venda_ID	0
Categoria	0
store_city	0
Região	0
store_name	0
Loja_ID	0
Custo_Aquisição	0
Preço	0
Tamanho	0
Cor	0
product_name	0
Data da Venda	0
Produto_ID	0
Cidade	0
Idade	0
Gênero	0
customer_name	0
Cliente_ID	0
Preço Unitário	0
Quantidade	0
Tipo	0

```
Duplicate rows: 0
```

Data Preprocessing

Data Consistency

Pengecekan data consistency dilakukan untuk memastikan setiap data memiliki format, nilai, dan hubungan antar-key yang konsisten sebelum dianalisis.

.Pada dataset ini, pemeriksaan meliputi:

- **Key Consistency** — memastikan sale_id, customer_id, product_id, dan store_id terhubung dengan benar.
- **Data Type Consistency** — memastikan numerical, categorical, dan datetime menggunakan tipe data yang sesuai.
- **Category Consistency** — menstandarkan penulisan kategori dan menerjemahkan nilai kategorikal agar seragam.
- **Logical Consistency** — memastikan nilai seperti quantity, unit_price, acquisition_cost, dan revenue tidak memiliki nilai yang tidak logis.

	count	mean	std	min	25%	50%	75%	max
Venda_ID	20000.0	10000.500000	5773.647028	1.00	5000.7500	10000.500	15000.250	20000.00
Quantidade	20000.0	50.451050	28.919985	1.00	25.0000	50.000	75.000	100.00
Preço Unitário	20000.0	501.006653	288.182446	2.07	253.6775	503.465	750.495	999.92
Cliente_ID	20000.0	501.651900	288.377360	1.00	253.0000	500.000	752.000	1000.00
Idade	20000.0	44.534150	15.487467	18.00	30.0000	45.000	58.000	70.00
Produto_ID	20000.0	500.696350	288.268000	1.00	252.7500	501.000	750.000	1000.00
Preço	20000.0	60.607306	23.132910	20.08	40.9900	61.085	80.210	99.92
Custo_Aquisição	20000.0	30.154807	11.561283	10.02	19.9500	30.470	40.020	49.97
Loja_ID	20000.0	3.012650	1.411768	1.00	2.0000	3.000	4.000	5.00

	count	unique	top	freq
Data da Venda	20000	20000	2020-04-19 13:51:40	1
customer_name	20000	986	Benedita Amaral	68
Género	20000	2	M	10508
Cidade	20000	221	Lagos	342
product_name	20000	182	Modi	304
Categoria	20000	2	Roupas	10011
Cor	20000	10	Vermelho	2259
Tamanho	20000	17	XS	1885
store_name	20000	5	Loja Araújo S/A	4095
Região	20000	3	Centro	11992
store_city	20000	5	Ferreira do Alentejo	4095
Tipo	20000	2	Física	12014

Data Preprocessing

Column Standarization

Proses ini dilakukan untuk menyeragamkan nama kolom dan bahasa pada dataset, karena data awal menggunakan bahasa Portugis. Nama kolom diterjemahkan ke bahasa Inggris dan disesuaikan ke format yang konsisten agar lebih mudah dipahami, dianalisis, dan digunakan pada dashboard.

```
column_translation = {
    "Venda_ID": "sale_id",
    "Data da Venda": "datetime",
    "Quantidade": "quantity",
    "Preço Unitário": "unit_price",
    "Cliente_ID": "customer_id",
    "customer_name": "customer_name",
    "Género": "gender",
    "Idade": "age",
    "Cidade": "customer_city",
    "Produto_ID": "product_id",
    "product_name": "product_name",
    "Categoria": "category",
    "Cor": "color",
    "Tamanho": "size",
    "Preço": "product_price",
    "Custo_Aquisição": "acquisition_cost",
    "Loja_ID": "store_id",
    "store_name": "store_name",
    "Região": "region",
    "store_city": "store_city",
    "Tipo": "store_type",
}

df_clean = df.rename(columns=column_translation).copy()

# Rename to a consistent lower_snake_case style if any mapped names still contain spaces
df_clean.columns = [c.strip().replace(" ", "_") for c in df_clean.columns]

df_clean.head()
```

Feature Engineering

Feature Engineering dilakukan untuk membuat variabel baru dari data yang sudah tersedia agar dapat memberikan informasi yang lebih relevan untuk analisis bisnis.

Pada dataset ini, feature engineering dibagi menjadi tiga bagian:

- Business Metrics — membuat Revenue, Total Cost, Profit, dan Profit Margin untuk mengukur performa finansial setiap transaksi.
- Customer Segmentation — membuat Age Group untuk mengelompokkan pelanggan berdasarkan rentang usia.
- Time Features — mengekstrak Year, Month, Quarter, Weekday, dan Weekend dari tanggal transaksi untuk menganalisis pola penjualan berdasarkan waktu.

margin_pct	age_group	sale_year	sale_month	sale_month_num	sale_quarter	sale_weekday	is_weekend
80.355924	18-24	2020	April	4	Q2	Sunday	True
83.856233	55-64	2016	May	5	Q2	Monday	False
93.697430	25-34	2018	November	11	Q4	Friday	False
91.852257	35-44	2024	December	12	Q4	Tuesday	False
85.486522	65+	2019	March	3	Q1	Thursday	False

Outliers

Outlier detection dilakukan untuk mengidentifikasi nilai yang jauh berbeda dari mayoritas data dan berpotensi memengaruhi hasil analisis statistik.

Outlier tidak langsung dihapus, karena nilai transaksi yang tinggi masih dapat merepresentasikan aktivitas penjualan yang valid dan justru dapat mengandung informasi bisnis penting.





	column	lower_bound	upper_bound	outlier_count	outlier_pct
0	quantity	-50.00000	150.00000	0	0.00
1	unit_price	-491.54875	1495.72125	0	0.00
2	age	-12.00000	100.00000	0	0.00
3	product_price	-17.84000	139.04000	0	0.00
4	acquisition_cost	-10.15500	70.12500	0	0.00
5	revenue	-40001.85625	85269.93375	257	1.29
6	total_cost	-1763.45625	4620.09375	89	0.45
7	profit	-39696.53250	82037.20750	267	1.33

Exploratory Data Analysis

Price Distribution

Analisis distribusi dilakukan untuk memahami bagaimana nilai pada variabel numerik tersebar, termasuk bentuk distribusi, tingkat kemencengan (***right-skewed***), dan keberadaan nilai ekstrem.


Pada analisis ini, Variabel numerik utama menunjukkan distribusi **tidak normal** berdasarkan Shapiro-Wilk Test dan beberapa pemeriksaan visual. Oleh karena itu, analisis faktor menggunakan pendekatan non-parametrik seperti **Spearman Correlation** dan **Kruskal-Wallis Test**.



Exploratory Data Analysis

Heatmap Correlation

Spearman Correlation Heatmap menunjukkan bahwa **Revenue** terutama memiliki hubungan kuat dengan komponen transaksi seperti **Quantity dan Unit Price**, sementara karakteristik seperti Age dan Acquisition Cost menunjukkan hubungan yang relatif lemah.




Numerical Factor Analysis

Spearman Correlation

Grafik ini menunjukkan kekuatan hubungan variabel numerik terhadap Revenue menggunakan Spearman Correlation (ρ). Semakin mendekati 1, semakin kuat hubungan positif dengan Revenue.

Dari grafik terlihat bahwa:

- Profit (~ 1.00) memiliki hubungan paling kuat dengan Revenue. Namun, karena Profit dihitung langsung dari Revenue dan Cost, hubungan ini bersifat matematis/derived dan tidak tepat dianggap sebagai faktor independen penyebab Revenue.
- Unit Price (~ 0.67) dan Quantity (~ 0.67) menunjukkan hubungan positif yang cukup kuat. Ini merupakan temuan paling penting karena Revenue memang meningkat seiring kombinasi harga dan jumlah unit yang terjual.
- Profit Margin (~ 0.58) dan Total Cost (~ 0.57) menunjukkan hubungan positif moderat dengan Revenue, tetapi keduanya juga merupakan variabel turunan/terkait langsung dengan komponen transaksi.
- Age (~ 0.00) dan Acquisition Cost (~ 0.00) hampir tidak memiliki hubungan monotonik dengan Revenue.




Categorical Factor Analysis

Kruskal-Wallis Test + Epsilon Squared (ϵ^2)


Digunakan untuk menguji apakah terdapat perbedaan Revenue yang signifikan antar kelompok kategorikal. Dari hasila analisa, **revenue tidak menunjukkan perbedaan yang signifikan** berdasarkan segmentasi kategorikal yang diuji. Faktor transaksi seperti **Quantity dan Unit Price** menunjukkan hubungan yang lebih kuat dengan Revenue dibandingkan karakteristik kategori.

	factor	p_value	epsilon_squared	effect_size	statistically_significant_0.05
0	sale_quarter	0.110437	0.000151	Negligible	False
1	region	0.094338	0.000136	Negligible	False
2	sale_weekday	0.345863	0.000037	Negligible	False
3	gender	0.188322	0.000037	Negligible	False
4	age_group	0.950716	0.000000	Negligible	False
5	category	0.552523	0.000000	Negligible	False
6	color	0.684386	0.000000	Negligible	False
7	size	0.848410	0.000000	Negligible	False
8	store_type	0.999746	0.000000	Negligible	False
9	sale_month	0.528809	0.000000	Negligible	False
10	is_weekend	0.751124	0.000000	Negligible	False



Bagaimana performa penjualan retail selama periode observasi?

- Total Revenue mencapai sekitar **€505.16M**, dengan Total Profit sekitar **€474.74M**, dari 20.000 transaksi dan **1.01M unit terjual**.
- Revenue tahunan menunjukkan pola yang fluktuatif, dengan peningkatan kuat **menuju 2018**, kemudian mengalami penurunan dan kembali **berfluktuasi pada periode berikutnya**.
- Hal ini menunjukkan bahwa performa penjualan tidak mengalami **pertumbuhan yang konsisten setiap tahun**, sehingga perubahan antarperiode perlu **diperhatikan** dalam perencanaan penjualan.



€ 505.16M

Total Revenue

€ 474.74M

Total Profit

20000

Total Transaction

1.01M


Unit Sold

€ 25.26K

Average Order Value

Faktor apa yang paling berkaitan dengan Revenue?


- Hasil Spearman Correlation menunjukkan bahwa **Unit Price dan Quantity memiliki hubungan positif yang paling kuat** dengan Revenue di antara variabel input utama.
- Sementara itu, **Age dan Acquisition Cost** menunjukkan hubungan yang sangat lemah terhadap Revenue.
- Hasil Kruskal-Wallis Test juga menunjukkan bahwa faktor kategorikal seperti region, category, age group, gender, dan periode penjualan tidak memiliki perbedaan Revenue yang signifikan secara statistik ($p > 0.05$) dan seluruh effect size tergolong negligible.
- Dengan demikian, performa Revenue pada dataset ini lebih erat berkaitan dengan **karakteristik transaksi**—terutama harga dan jumlah unit—dibandingkan segmentasi kategorikal yang diuji.



	factor	p_value	epsilon_squared	effect_size	statistically_significant_0.05
0	sale_quarter	0.110437	0.000151	Negligible	False
1	region	0.094338	0.000136	Negligible	False
2	sale_weekday	0.345863	0.000037	Negligible	False
3	gender	0.188322	0.000037	Negligible	False
4	age_group	0.950716	0.000000	Negligible	False
5	category	0.552523	0.000000	Negligible	False
6	color	0.684386	0.000000	Negligible	False
7	size	0.848410	0.000000	Negligible	False
8	store_type	0.999746	0.000000	Negligible	False
9	sale_month	0.528809	0.000000	Negligible	False
10	is_weekend	0.751124	0.000000	Negligible	False

Kategori, lokasi, dan segmen mana yang memberikan kontribusi terbesar terhadap Revenue?

- Kontribusi Revenue berdasarkan kategori produk relatif seimbang, dengan **Footwear sekitar €253.75M dan Clothing sekitar €251.41M**, sehingga bisnis **tidak terlalu bergantung** pada satu kategori produk.
- Kontribusi Revenue antar lokasi toko **relatif seimbang**, dengan masing-masing lokasi menghasilkan **sekitar €100M–€102M**. Hal ini menunjukkan bahwa Revenue **tidak bergantung** pada satu lokasi tertentu.
- Kelompok **usia 55–64 tahun** memberikan kontribusi Revenue terbesar, yaitu sekitar **€99.88M (19.77%)**, sehingga menjadi segmen pelanggan dengan kontribusi penjualan tertinggi.
- Namun, perbedaan kontribusi tersebut tidak berarti faktor tersebut secara statistik memengaruhi Revenue, karena hasil pengujian kategorikal sebelumnya menunjukkan effect size yang negligible.



Conclusion

Berdasarkan hasil analisis Retail Sales Performance & Revenue Analysis, diperoleh beberapa kesimpulan utama:

- Bisnis menghasilkan **Total Revenue €505.16M dari 20K transaksi dan 1.01M unit terjual**, dengan pola revenue tahunan yang berfluktuasi dan belum menunjukkan pertumbuhan yang konsisten.
- Quantity dan Unit Price merupakan variabel transaksi yang memiliki **hubungan paling kuat** dengan Revenue. Sebaliknya, Age dan Acquisition Cost menunjukkan hubungan yang sangat lemah.
- **Faktor kategorikal** seperti region, product category, age group, gender, dan periode penjualan tidak menunjukkan perbedaan Revenue yang signifikan secara statistik, dengan effect size yang negligible.
- **Kontribusi kategori produk relatif seimbang** antara Footwear (€253.75M) dan Clothing (€251.41M), sehingga tidak terdapat ketergantungan Revenue yang besar pada satu kategori.

Recommendation

Optimalkan Volume Sales dan Strategi Pricing

Terapkan bundling, volume-based promotion, dan evaluasi pricing untuk mendorong **peningkatan revenue** tanpa mengorbankan profitabilitas.

Monitorisasi Sales Trends & High-Contribution Segments

Gunakan monitoring berkala berdasarkan time period, store/location, dan customer segment untuk mendeteksi perubahan performa lebih awal.

Imbangkan Kontribusi Produk

Kontribusi Revenue antara Footwear (€253.75M) dan Clothing (€251.41M) relatif seimbang. Tidak ada satu kategori yang mendominasi secara ekstrem. **Pertahankan investasi pada kedua kategori** dan prioritaskan produk individual dengan kombinasi Revenue dan Profit terbaik, bukan hanya berdasarkan kategori.

Thank you!

CONTACT



+62 857 2014 1459



izzanmfaiz@gmail.com



Izzan Muhammad Fa'iz



<https://github.com/ImaWeaverBear>